

Predicción: Series Temporales




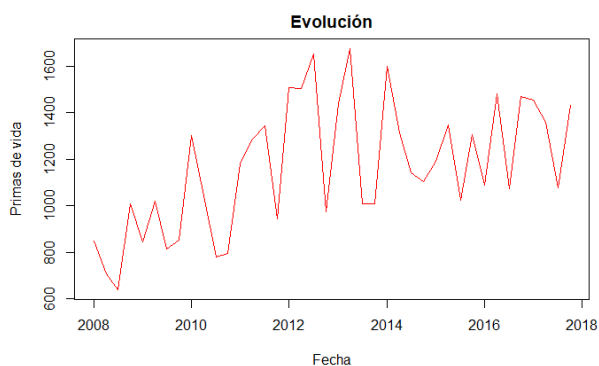
Carlota Echevarría

13/11/2019

El objetivo de este trabajo es predecir la prima de los seguros de Mapfre para el año 2018, mediante la estimación de los modelos ETS y ARIMA y comparar ambos según los resultados.


Nuestra base de datos contiene 4 variables de 40 observaciones y distribuidas en cuatrimestres desde 2008 hasta 2018, nuestras observaciones a predecir son las primas de seguro de vida y las de no vida. Se realizará la predicción de 2017 y 2018.

Ambas series no son estacionarias en media ni varianza, la tendencia es creciente y presentan estacionalidad.




Se ha realizado la suma de las primas de vida y no vida, para realizar la estimación de los modelos y posteriormente la predicción.

Se explicará primero el modelo ETS, seguido del modelo ARIMA.



Modelo ETS:


En el primer y segundo trimestre del año las primas de seguros son más elevadas, y el tercer trimestre más reducida.



Se ha estimado el modelo ETS, se trata de un modelo aditivo amortiguado y se ha realizado una predicción para las primas de seguros de los cuatrimestres de 2017 y 2018.

Respecto a la predicción de 2017, comparamos la observación la predicción y se observa que la predicción de los dos primeros cuatrimestres esta por debajo de la realidad, respecto al tercer y cuarto trimestre por encima.

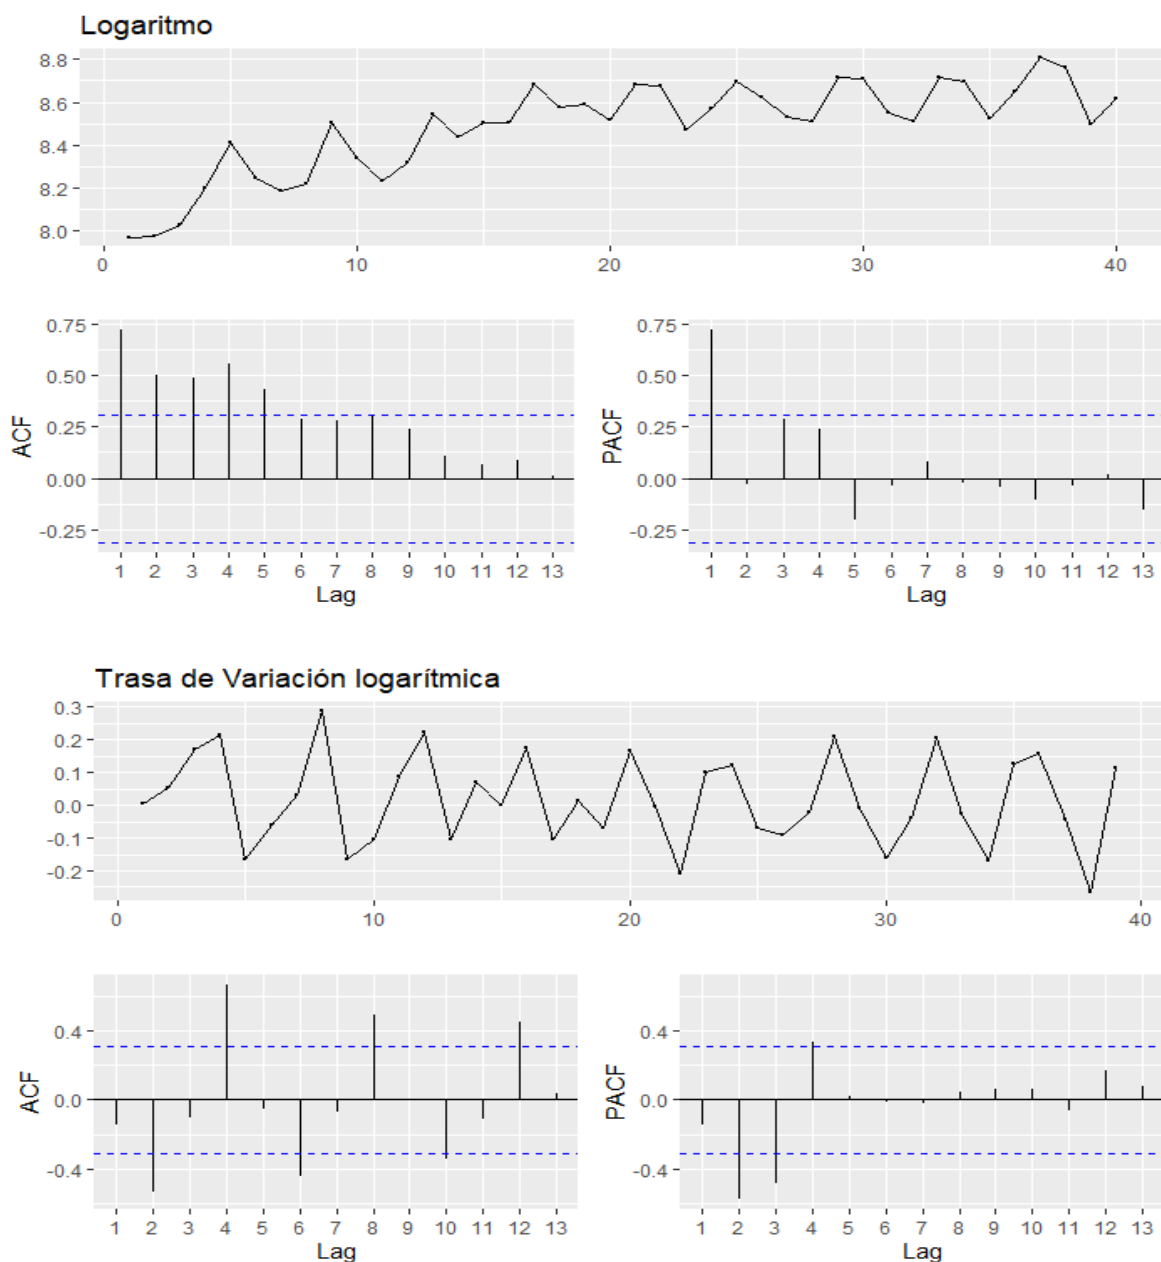
Es el resultado de que las primas son más elevadas en el primer y segundo cuatrimestre, y en el tercer y cuarto disminuyen notablemente. El resultado más favorable de la predicción es el del cuarto, puesto que es en el que las primas se estabilizan.



Predicción VS Observación			
	Predicción	Observación	Error
2017 Q1	6360.1	6674.6	314.5
2017 Q2	5930.4	6398.6	468.2
2017 Q3	5490.8	4913.4	-577.44
2017 Q4	5528.5	5507.2	-21.3

Modelo ARIMA:

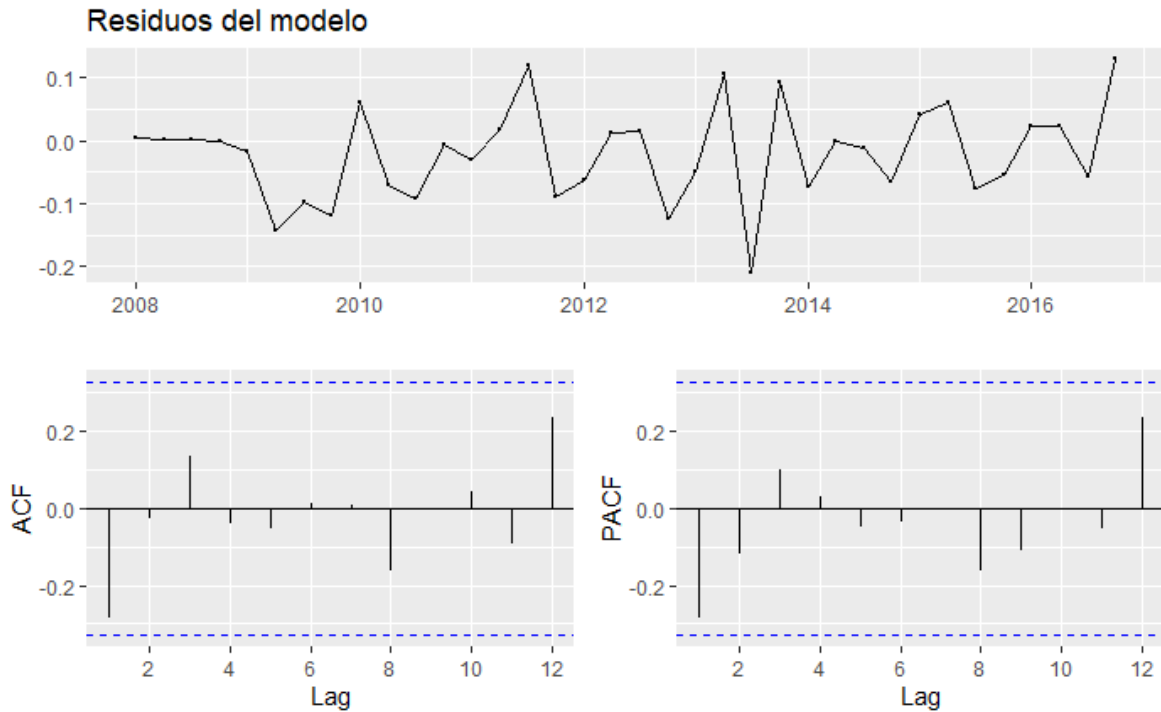
Se ha observado anteriormente que la serie no es estacionaria ni en media ni varianza, por lo que se ha realizado una tasa de variación logarítmica, convirtiendo la serie en estacionaria tanto en varianza como en media.




Tras convertir la serie en estacionaria, con la función de autocorrelación simple intuimos que hay un componente estacional en nuestra serie.

Procedemos a calcular el modelo y se obtiene el modelo: $ARIMA(0,1,0) * (0,1,1)_4$.

Se observa que las autocorrelaciones (tanto simples como parciales) se encuentran dentro de las bandas de confianza, lo que indica que los residuos están incorrelados. Adicionalmente se realiza el contraste Ljung-Box, cuyo p-valor es mayor a un nivel de significatividad del 5%, por tanto, a través del contraste, podemos decir que las autocorrelaciones son iguales a cero.



Se observa que la predicción de los cuatrimestres de 2017, las primas son más elevadas que en los valores observados, y que el mayor error se encuentra en el tercer trimestre.



Predicción VS Observación			
	Predicción	Observación	Error
2017 Q1	6912.2	6674.6	-237.6
2017 Q2	6652.4	6398.6	-253.8
2017 Q3	5814.4	4913.4	-901
2017 Q4	6085.5	5507.2	-578.3

Conclusión:

Comparando ambos modelos, el error obtenido en el primer y segundo cuatrimestre es menor con el modelo ARIMA, pero el error del modelo ETS en el tercer y cuarto cuatrimestre es menor.

Si comparamos el error cuadrático medio de ambos modelos, concluimos que el **mejor modelo de estimación es el ETS**.

- RMSE (ETS): 308.6
- RMSE (ARIMA): 388.9

	Comparación del ERROR de ambos modelos	
	Error ETS	Error ARIMA
2017 Q1	314.5	-237.6
2017 Q2	468.2	-253.8
2017 Q3	-577.44	-901
2017 Q4	-21.3	-578.3

Bibliografía:

Hyndman, R. J., A. B. Koehler, J. K. Ord and R. D. Snyder (2008). Forecasting with exponential smoothing: the state space approach. Berlin: Springer-Verlag.

Anexo- Código:

#Library

```
library(readr)
require(forecast)
require(xts)
require(ggplot2)
library(ggfortify)
library(dplyr)
```

#Datos

```
Primas_mapfre <- read.csv("data/Primas_mapfre.csv", header = TRUE,
  sep = ";", dec = "," )
View(Primas_mapfre)
```

#Suma de primas

```
Primas_mapfre$Suma <- (Primas_mapfre$Primas_vida + Primas_mapfre$Primas_n
o_vida)
```

#Análisis Exploratorio

```
primas_ts <- ts(Primas_mapfre$Suma, start = c(2008,1), frequency = 4)
primas_desc <- decompose(primas_ts)
plot(primas_desc, col = "blue")
```

#Conversión de datos

```
xPrimas = xts(Primas_mapfre$Suma, order.by = as.Date(Primas_mapfre$Fecha,
"%m/%d/%Y"),frequency=4)
```

#Generate quarterly data

```
xPrimas = to.quarterly(xPrimas)
```

#Transform to zoo data (forecast package)

```
zPrimas = as.zoo(xPrimas$xPrimas.Close)
names(zPrimas)="Primas"
```

##Plot Serie

```
autoplot(zPrimas)+ggtitle("Primas trimestrales")+xlab("Trimestres")+ylab(
"Primas")
```

#Seasonal Plot

```
ggfreqplot(as.ts(zPrimas),freq=4,nrow=1,facet.labeller=c("1T","2T","3T","
4T"))+ggtitle("Primas Trimestrales")
```



```

#Select number of observation to compare forecast
cOmit=4

#Data Size
nObs=length(zPrimas)

#sub_sample
#oVentas=zVentas[1:(nObs-cOmit),]
oPrimas <- window(zPrimas,start=index(zPrimas[1]),end=index(zPrimas[nObs-
cOmit]))
View(oPrimas)

```

Modelo ETS

```

## Select automatic ETS
etsfit<-ets(oPrimas,damped=TRUE)

#forecast model
fprimas.ets=forecast(etsfit)

#Results
summary(fprimas.ets)

Forecast method: ETS(A,Ad,A)

Model Information:
ETS(A,Ad,A)

Call:
ets(y = oPrimas, damped = TRUE)

Smoothing parameters:
  alpha = 0.2424
  beta  = 1e-04
  gamma = 1e-04
  phi   = 0.9505

Initial states:
  l = 2931.1472
  b = 178.7185
  s = -335.3013 -349.5291 114.6065 570.2239

sigma: 356.3793

```

	AIC	AICc	BIC
	561.7218	570.5218	577.5570

Error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-5.403611	308.6335	249.7589	-0.4948873	5.595178	0.6033052

ACF1

Training set 0.1276507

Forecasts:

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
2017 Q1	6360.067	5903.349	6816.786	5661.577	7058.558
2017 Q2	5930.371	5460.419	6400.324	5211.641	6649.102
2017 Q3	5490.845	5008.011	5973.679	4752.414	6229.275
2017 Q4	5528.540	5033.151	6023.929	4770.908	6286.172
2018 Q1	6456.184	5948.533	6963.836	5679.798	7232.570
2018 Q2	6021.727	5502.104	6541.349	5227.033	6816.421
2018 Q3	5577.675	5046.343	6109.006	4765.074	6390.276
2018 Q4	5611.068	5068.274	6153.862	4780.937	6441.200

```
#Plot
plot(fprimas.ets)
lines(window(zPrimas),type="o")
```

```
#Actual and Forecast
matrix(c(fprimas.ets$mean[1:cOmit],zPrimas[(nObs-cOmit+1):nObs]),ncol=2)
```

Modelo ARIMA

```
zPrimas_log = log(zPrimas)
df_new1 <- data.frame(value = as.vector(zPrimas_log),
                      time = time(zPrimas_log))
ggplot(df_new1)+geom_point(aes(x=time,y=value))+geom_line(aes(x=time,y=value))
+ylab("Primas")+ggtitle("Modelo ARIMA")+xlab("Años")
```

```
#Estacionaria en varianza
ggtsdisplay(zPrimas_log)
```

```
#Estacionaria en media
ggtsdisplay(diff(zPrimas_log))
```

```
fit1=auto.arima(oPrimas,lambda=0)
summary(fit1)
```

```
Series: oPrimas
ARIMA(0,1,0)(0,1,1)[4]
Box Cox transformation: lambda= 0
```

```
Coefficients:
```

```
      sma1
      -0.6185
s.e.    0.1830
```

```
sigma^2 estimated as 0.007238:  log likelihood=31.97
AIC=-59.94  AICc=-59.51  BIC=-57.07
```

```
Training set error measures:
```

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-93.54831	388.8768	301.9985	-2.36378	6.164447	0.7294924

```
ACF1
Training set -0.3575378
```

```
#residual analysis
ggtsdisplay(fit1$residuals)
```

```
#box-Ljung Test
```

```
Box.test(fit1$residuals,lag=6, fitdf=3, type="Lj")
Box-Ljung test
```

```
data: fit1$residuals
X-squared = 4.1928, df = 3, p-value = 0.2414
```

```
Box.test(fit1$residuals,lag=8, fitdf=3, type="Lj")
Box-Ljung test
```

```
data: fit1$residuals
X-squared = 5.4651, df = 5, p-value = 0.3618
```

```
Box.test(fit1$residuals,lag=12, fitdf=3, type="Lj")
Box-Ljung test
```

```
data: fit1$residuals  
X-squared = 9.1663, df = 9, p-value = 0.4221
```

```
Box.test(fit1$residuals, lag=24, fitdf=3, type="Lj")  
Box-Ljung test
```

```
data: fit1$residuals  
X-squared = 20.534, df = 21, p-value = 0.4877
```

```
df_new <- data.frame(value = as.vector(zPrimas), time = time(zPrimas))  
ggplot(df_new)+geom_point(aes(x=time,y=value))+geom_line(aes(x=time,y=value))+  
geom_forecast(fprimas.arima,alpha=0.4)+xlab("Fecha")+ylab("Primas")  
+ggtitle("ARIMA: Predicción Primas") + theme_bw()  
fprimas.arima
```